

# HyperParameter

## **1-VotingClassifier**

**Estimators: list of tuples like:**

estimators=[('lr', log\_clf), ('rf', rnd\_clf), ('svc', svm\_clf)]

**voting: string:**

voting='hard'

ده عن طريق predict class ثم بياخذ ال Majority of vote.

voting='soft'

ده لما تكون ال models المستخدمة في ال Voting بتقدر تتوقع ال probabilities ساعتها بدل ال Hard voting عن طريق ال Majority ، لا ده بيروح يشوف مجموع ال probability بتاعت كل class ويقسم على عدد ال models بعد كده يشوف لو كانت المجموع ده اكبر من ال threshold ولا اقل وبناء عليه يعمل assign ل class معين.  
ده بيدى نتائج افضل.

## **2-BaggingClassifier**

**Base\_estimator: object if left use DecisionTree()**

انهي موديل عايز تستخدمه.

**N\_estimators: int**

عدد ال models الى عايز تعملها run من ال model المستخدم .

**Max\_samples: int or float**

عدد ال training instance الى عايز تعمل عليهم train في كل estimator من ال n-estimators . او تعملها كنسبة بين 0 - 1 ك float number.

**Max\_features: int or float**

كمان تقدر تتحكم فى عدد ال features المستخدمة زى عدد ال instance بظبط ، وكمان تقدر تحدد النسبة برضه .

### **bootstrap=True as default value**

التغير من Bagging method ل Pasting عن طريق ال bootstrap الأساس هو Bagging لو هحول ل Pasting هخليها False ، الفرق بينهم فى ال Summary والى هو فى استخدام نفس ال subset ولا لا.

### **bootstrap\_features=False as default value**

زى bootstrap لو عايز كمان ال features تختارها random هتخليه ب True .

### **oob\_score=False as default value**

لما كل model يعمل run على جزء فقط من ال data فيه جزء تانى ال model مش هيشوفة خالص ، فهنا لو خليت ال oob\_score=True بكدة هعمل على الجزء الى ال model مش هيشوفة Evaluation بدل ما اروح استخدم Croos-validation او اى طريقة لل Evaluation .

### **warm\_start=False as default**

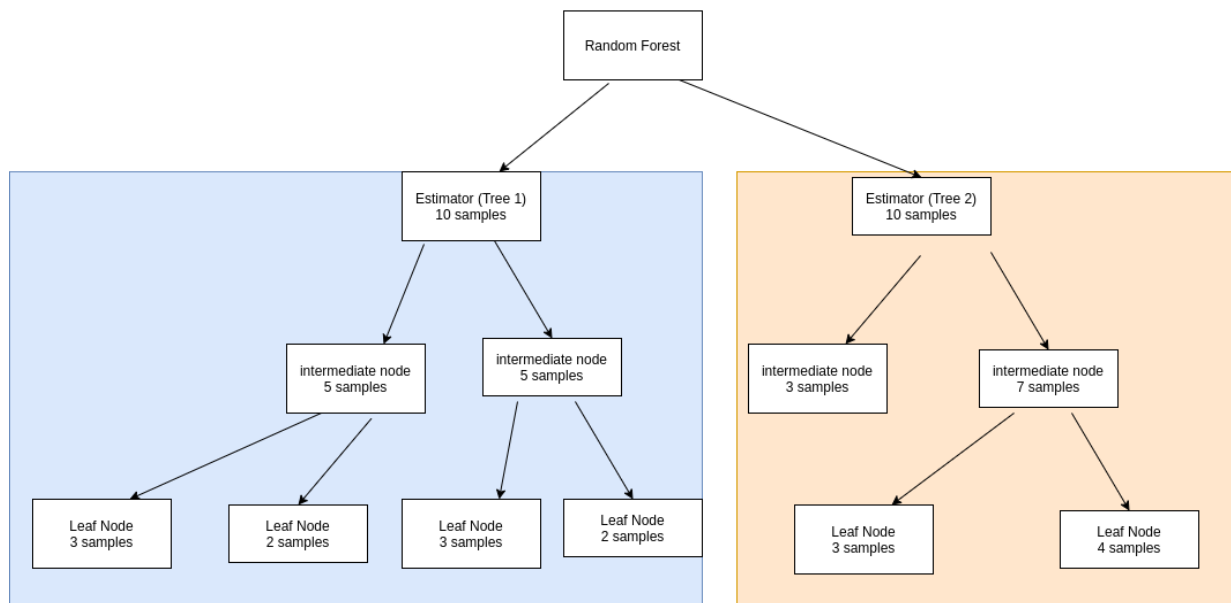
لو خليتها ب True هتستخدم اخر نتيجة وصلتها من ال fitting الى عملته عشان تكمل عليها لما اجى اعمل run لل model من تانى ، لكن وهى False كده فى كل مرة بعمل fit بيعمل training من اول وجديد .

### **n\_jobs=int**

لو خليتها n\_jobs=-1 هتعمل run باستخدام كل ال CPUs المتاحة ، فهى بتخلينى ققدر اعمل run على التوازي ، وده لان كل model اصلا منفصل عن التانى .

## ***3-RandomForest***

**N\_estimators = 2**  
**Max\_depth = 2** (look at estimator not Random Forest node)  
**Min\_samples\_split: 4**  
**min\_samples\_leaf: 2**  
**max\_leaf\_nodes:4**



هو عبارة عن ensemble من ال Decision Tree عشان تستخدمه علطول ، فهو عنده معظم ال hyperparam بتاعت Decision Tree بلس ال HyperParam الخاصة بال Ensemble method .

## **N\_estimators: int**

عدد ال models الى عايز تعملها run من ال model المستخدم ، ده خاص بال Ensemble method .

## **criterion{"gini", "entropy"}, default="gini"**

انهى نوع من ال loss function محتاج تطبقه من الموديل ده خاص بال Decision Tree.

## **Max\_depth:int, None as default**

طول ال Tree فى كل estimator آخرها اد ايه وده خاص بال Decision Tree .

## **Min\_samples\_split:int:int or float default=2**

أقل عدد من ال instance يكون موجود في ال Node عشان يحصل split وده خاص بال Decision Tree .

**min\_samples\_leaf:int or float, default=1**

أقل عدد من instances يكون موجود في ال leaf node وده خاص بال Decision Tree .

**max\_leaf\_nodes:int, default=None**

أقصى عدد من leaf nodes ممكن يكون موجود في كل Tree وده خاص بال Decision Tree .

**باقي ال Params معظمها زي ال في BaggingClassifier .**

## **4-ADABOOST**

**Base\_estimator: object if left use DecisionTree()**

انهي موديل عايز تستخدمه وعلى حسب بقا ال hyper param بتاعت ال model نفسه انتا مظبطها ازاي هو هيعمل Train بيها .

**N\_estimators: int**

عدد ال models ال عايز تعملها run من ال model المستخدم .

**Learning\_rate: float, default=1.0**

ال learning rate يتناسب عكسي مع عدد ال estimator عشان تقدر تتحكم في ال regularization.

**algorithm{'SAMME', 'SAMME.R'}, default='SAMME.R'**

ال default شغال بال probability بينما الاخر بيحيب ال pediction عطلول .

## 4-Gradient Boost

نفس موضوع ال Random Forest برضه خاص بال Decision Tree بس بدل ما بيرن على التوازي زي ال Random Forest لا بيرن بطريقة Sequential زي ما وضعنا في البوستات والملخص.

نفس ال HyperParams في ال فاتوا .

تَمَّ بِحَمْدِ اللَّهِ .